




# Model Klasifikasi untuk Prediksi Risiko Gagal Membayar Pinjaman

Virtual Internship Program - Data  
Scientist

Oleh : Muhammad Ali Umar

# Problem Statement

- *Credit Risk* adalah risiko kerugian yang dihadapi pemberi pinjaman karena kegagalan peminjam untuk membayar kembali semua jenis pinjaman atau hutang.
- Diperlukan waktu yang lama jika kita melakukan penilaian secara manual. Hal ini dapat terjadi jika kita membuat keputusan yang salah dan akan menyebabkan kerugian yang cukup besar.
- Kerugian Finansial Kredit adalah jumlah uang yang hilang oleh pemberi pinjaman ketika pemohon menolak untuk membayar atau melarikan diri dengan uang yang terutang.





## GOAL & OBJECTIVE

Membuat suatu model yang dapat menentukan suatu pengguna mampu atau tidak mampu membayar kredit.



## ANALYTICS APPROACH

Melihat permasalahan yang ada, aku akan membangun model *machine learning*, karena perlu membangun prediksi lebih dari sekedar menggunakan pendekatan analisis inferensial atau deskriptif.



## MODELLING

Aku akan mencoba 6 model *machine learning*: Logistic Regression, XGB, Decision Tree, Random Forest, Naive Bayes, LGBM.


# Dataset




*Dataset sample* yang digunakan berisi data pinjaman yang diterima maupun yang ditolak dan terdiri dari:

- **466.285 Baris**
- **75 Kolom**
- **22 Tipe Data Kategorik**
- **53 Tipe Data Numerik**


# Insight



Semakin banyak *total principal received* atau total pokok hutang yang telah dibayarkan *customer*, proporsi keberhasilan pembayarannya juga cenderung tinggi dibandingkan total pokok hutang yang nominalnya lebih kecil.



- . Semakin besar *interest rate* atau bunga pinjaman, *customer* cenderung mengalami kesulitan membayar. Terlihat dari proporsi keberhasilan pembayaran, dimana bunga pinjaman lebih dari **22%**, proporsi *customer* mengalami kesulitan bayar lebih dari **20%**.



*Customer* yang melakukan pengajuan pinjaman dana dengan tujuan produktif, proporsi mengalami kesulitan bayar cenderung lebih tinggi dibandingkan dengan tujuan multiguna (kebutuhan konsumtif).

Oleh karena itu perlu dilakukan analisis terhadap jenis bisnis *customer*, agar diketahui jenis bisnis seperti apa yang memiliki potensi mengakibatkan *customer* mengalami kesulitan pembayaran *credit*.



# Data Cleansing & Preprocessing

- 
- ```
graph LR; A["• Drop kolom dengan Missing Value ≥ 50%.  
• Missing Value kurang dari 50% dan di atas 1% di input dengan median.  
• Tidak ada data duplicated di dataset ini."] --> B["• Feature Selection dilakukan dengan menggunakan Uji Statistik dan Heatmap Correlation. Hasilnya 21 fitur digunakan (tidak termasuk TARGET)."]; B --> C["• Deteksi outlier dengan box-plot dan QQPlot. Outlier yang bertipe global outlier akan dihapus dari baris."]; C --> D["• Mengatasi imbalanced data menggunakan Class Weight."]; D --> E["• Standard Scaler untuk Variabel numerik.  
• Ordinal Encoding : Data ordinal dan data nominal yang memiliki 2 kelompok.  
• OneHot Encoding : Data nominal > 2 kelompok."]; E --> F["• Melakukan feature engineering pada variable/kolom home_ownership, purpose, term, dan earliest_cr_line.  
• Menghapus kolom earliest_year (hasil feature engineering earliest_cr_line) yang memiliki nilai negative."];
```
- Drop kolom dengan *Missing Value*  $\geq 50\%$ .
  - *Missing Value* kurang dari 50% dan di atas 1% di *input* dengan *median*.
  - Tidak ada data *duplicated* di *dataset* ini.
- *Feature Selection* dilakukan dengan menggunakan Uji Statistik dan *Heatmap Correlation*. Hasilnya **21 fitur** digunakan (tidak termasuk **TARGET**).
- Deteksi *outlier* dengan *box-plot* dan *QQPlot*. *Outlier* yang bertipe *global outlier* akan dihapus dari baris.
- Mengatasi *imbalanced data* menggunakan **Class Weight**.
- **Standard Scaler** untuk Variabel numerik.
  - **Ordinal Encoding** : Data ordinal dan data nominal yang memiliki 2 kelompok.
  - **OneHot Encoding** : Data nominal  $> 2$  kelompok.
- Melakukan *feature engineering* pada variable/kolom **home\_ownership**, **purpose**, **term**, dan **earliest\_cr\_line**.
  - Menghapus kolom **earliest\_year** (hasil *feature engineering* **earliest\_cr\_line**) yang memiliki nilai *negative*.

# Modelling

| Model               | Training AUC_ROC | CV AUC_ROC (mean) | CV AUC_ROC (std) | Gap AUC_ROC |
|---------------------|------------------|-------------------|------------------|-------------|
| Logistic Regression | 0.7863           | 0.8632            | 0.0024           | 0.0769      |
| XGB                 | 0.8369           | 0.9345            | 0.0018           | 0.0976      |
| Decision Tree       | 1.0000           | 0.8238            | 0.0029           | 0.1762      |
| Random Forest       | 0.9999           | 0.9141            | 0.0032           | 0.0857      |
| Naive Bayes         | 0.5809           | 0.7973            | 0.0038           | 0.2163      |
| LGBM                | 0.8733           | 0.9365            | 0.0014           | 0.0632      |

- Model yang digunakan adalah *Light Gradient Boosting Machine (LGBM)* dikarenakan gap antara score **AUC\_ROC** data *training* dan *cross validation test* cenderung lebih kecil dibandingkan model lain.
- Selain itu standard deviasi pada model **LGBM** adalah yang paling kecil. Nilai standard deviasi yang kecil maka performa modelnya cenderung lebih konsisten.





- Performa model lebih baik setelah dilakukan *hypertuning parameter*. Terlihat dari nilai *Gini* yang lebih besar dibandingkan sebelum *tuning hyperparameter*. Selain itu *AUC* setelah dilakukan *hypertuning* juga lebih besar nilainya.
- *Threshold* optimal yang diperoleh dengan menggunakan teknik *G-mean* adalah 0.427, dimana *customer* yang memiliki peluang lebih dari 0.427 akan terdeteksi kesulitan dalam pembayaran.



# Implementasi Model pada Data

Test

Data Test Menggunakan LGBM dengan Default Threshold



- Setelah diimplementasikan ke *Data Test* dari total **92.918 customer**, **16.189** diantaranya diprediksi mengalami kesulitan pembayaran.
- Nilai *AUC* pada *Data Test* **0.94** dan nilai *Gini* serta *KS* masih di atas **0.8**. Performa model masih cukup baik dalam melakukan prediksi pada *Data Test*.



- Semakin tinggi *Total Principal Received* atau total pokok hutang yang telah dibayarkan *customer*, maka semakin besar peluang *customer* mengalami kesulitan pembayaran.
- Semakin tinggi *Outstanding Principal* atau sisa pokok hutang *customer*, maka peluang *customer* mengalami kesulitan pembayaran juga cenderung besar.
- Semakin tinggi *Interest Rate* atau bunga pinjaman, maka semakin besar peluang *customer* mengalami kesulitan pembayaran.

# Link GitHub dan Youtube

**Link GitHub :**

<https://github.com/contekan-si-al/Final-Task-ID-X-Partners-Data-Scientist/tree/main>

**Youtube :**

[https://youtu.be/i\\_RqlI990\\_0](https://youtu.be/i_RqlI990_0)

# Terima Kasih

